



DEPARTAMENTO
DE COMPUTACION

Facultad de Ciencias Exactas y Naturales - UBA

Introducción a la Investigación Operativa y Optimización

Primer cuatrimestre 2025

Optimización no lineal multivariable

Dada $f : \mathbb{R}^n \rightarrow \mathbb{R}$ y $S \subseteq \mathbb{R}^n$, queremos resolver el problema:

$$\min_{x \in S} f(x)$$

- Si $S = \mathbb{R}^n$, es el caso de dominio no restringido.
- Si $S \subset \mathbb{R}^n$, es un problema de optimización con restricciones.

Optimización multivariada sin restricciones.

Condiciones necesarias - $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con $f \in C^2$

Condición de optimalidad de 1er orden

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^1$. Si x^* es un mínimo local de f , entonces $\nabla f(x^*) = 0$.

Demostración

Sea $d \in \mathbb{R}^n$.

- Definimos $\phi : \mathbb{R} \rightarrow \mathbb{R}$ como $\phi(\alpha) = f(x^* + \alpha d)$.
- Por regla de la cadena $\phi'(\alpha) = \nabla^T f(x^* + \alpha d)d$.
- Como x^* es un mínimo local de f , 0 es un mínimo local de ϕ .
- Por condición de optimalidad de 1er orden $\phi'(0) = 0$.
- $0 = \phi'(0) = \nabla^T f(x^*)d, \forall d \in \mathbb{R}^n$.
- Por lo tanto $\nabla f(x^*) = 0$.

Condiciones necesarias - $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con $f \in C^2$

Condición de optimalidad de 2do orden

Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^2$. Si x^* es un mínimo local de f , entonces $\nabla f(x^*) = 0$ y $Hf(x^*)$ semidefinida positiva.

Demostración


Sea $d \in \mathbb{R}^n$.

- Definimos $\phi : \mathbb{R} \rightarrow \mathbb{R}$ como $\phi(\alpha) = f(x^* + \alpha d)$.
- Por regla de la cadena $\phi''(\alpha) = d^t Hf(x^* + \alpha d) d$.
- Como x^* es un mínimo local de f , 0 es un mínimo local de ϕ .
- Por condición de optimalidad de 2do orden: $\phi'(0) = 0$ y $\phi''(0) \geq 0$.
- Entonces $\nabla^T f(x^*) d = 0$ y $\phi''(0) = d^t Hf(x^*) d \geq 0$, $\forall d \in \mathbb{R}^n$.
- Por lo tanto $\nabla f(x^*) = 0$ y $Hf(x^*)$ semidefinida positiva.

Condiciones necesarias - $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con $f \in C^2$

No es condición suficiente


- $f(x_1, x_2) = (x_1 - x_2^2)(x_1 - 2x_2^2) = x_1^2 - 3x_1x_2^2 + 2x_2^4$
- $\nabla f(x_1, x_2) = (2x_1 - 3x_2^2, -6x_1x_2 + 8x_2^3)$
- $Hf(x_1, x_2) = \begin{pmatrix} 2 & -6x_2 \\ -6x_2 & -6x_1 + 24x_2^2 \end{pmatrix}$



Condiciones necesarias - $f : \mathbb{R}^n \rightarrow \mathbb{R}$ con $f \in C^2$

No es condición suficiente

- $\nabla f(0,0) = 0$
- $Hf(0,0) = \begin{pmatrix} 2 & 0 \\ 0 & 0 \end{pmatrix}$ es semidefinida positiva.
- $(0,0)$ no es mínimo local. Tiene función objetivo $= 0$
- $x = (\epsilon, \sqrt{\frac{3\epsilon}{4}})$ tiene función objetivo $= -\frac{\epsilon^2}{8}$



Condición de optimalidad de 2do orden

Condición suficiente de 2do orden


Sea $f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^2$. Si x^* es un mínimo local de f , entonces $\nabla f(x^*) = 0$ y $Hf(x^*)$ definida positiva.

Demostración

Sea d una dirección factible.

- Definimos $g : \mathbb{R} \rightarrow \mathbb{R}$ como $g(\alpha) = f(x^* + \alpha d)$.
- Por regla de la cadena $g'(\alpha) = \nabla^T f(x^* + \alpha d)d$ y $g''(\alpha) = d^T Hf(x^* + \alpha d)d$.
- Como x^* es un mínimo local de f , 0 es un mínimo local de g . Entonces, por condición suficiente de optimalidad de 2do orden en una variable, $g'(0) = 0$ y $g''(0) > 0$.
- Como la región factible es todo \mathbb{R}^n , toda $d \in \mathbb{R}^n$ es dirección factible, y entonces $\nabla f(x^*) = 0$ y $g''(0) = d^T Hf(x^*)d > 0 \forall d \in \mathbb{R}^n$.
- Por lo tanto $\nabla f(x^*) = 0$ y $Hf(x^*)$ definida positiva.

Métodos de descenso



$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de descenso coordinado

- Minimiza la función objetivo iterativamente a lo largo de una coordenada a la vez, mientras mantiene las demás coordenadas fijas.
- Resuelve de forma secuencial el problema

$$\min_{x_i \in \mathbb{R}} f(x_1, \dots, x_n)$$

- Diferentes formas de seleccionar la siguiente coordenada sobre la cual optimizar:
 - aleatoria
 - cíclica
 - ida y vuelta: $e_1, e_2, \dots, e_{n-1}, e_n, e_{n-1}, \dots, e_2, e_1, \dots$
 - método de Gauss-Southwell: elige la coordenada que maximiza el gradiente en valor absoluto. Esto puede acelerar la convergencia al enfocarse en la dirección de mayor descenso en cada paso

$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de descenso coordinado


Algoritmo:

- ❶ Inicializar $x^0 \in \mathbb{R}^n$, $k \leftarrow 0$
- ❷ Mientras no se cumpla el **criterio de parada**:
 - ❶ Seleccionar una coordenada i según el criterio elegido
 - ❷ Resolver el problema univariable:


$$\lambda^k = \arg \min_{\lambda \in \mathbb{R}} f(x_1^k, \dots, x_{i-1}^k, x_i^k + \lambda, x_{i+1}^k, \dots, x_n^k)$$

- ❸ $x^{k+1} \leftarrow x^k + \lambda^k e_i$
- ❹ $k \leftarrow k + 1$

$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de descenso coordenado - Convergencia



$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de descenso coordenado - Divergencia



$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de Hooke y Jeeves

- Combina dos tipos de direcciones de búsqueda iterativamente.
- Primero realiza una vuelta del método de descenso coordinado cíclico.
- Luego toma como dirección $x^{k+1} - x^k$ (patrón de búsqueda).

$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de Hooke y Jeeves

Algoritmo:

- ❶ Inicializar $x^0 \in \mathbb{R}^n$, $k \leftarrow 0$, $y^0 \leftarrow x^k$
- ❷ Mientras no se cumpla el **criterio de parada**:

- ❶ Para $i = 1, \dots, n$:

- ❶ Resolver el problema univariable:

$$\lambda^i = \arg \min_{\lambda \in \mathbb{R}} f(y_1^{i-1}, \dots, y_{i-1}^{i-1}, y_i^{i-1} + \lambda, y_{i+1}^{i-1}, \dots, y_n^{i-1})$$

- ❷ $y^i \leftarrow y^{i-1} + \lambda^i e_i$

- ❷ $x^{k+1} \leftarrow y^n$

- ❸ $d^k \leftarrow x^{k+1} - x^k$

- ❹ Resolver el problema univariable:


$$\lambda^k = \arg \min_{\lambda \in \mathbb{R}} f(y^n + \lambda d^k)$$

- ❺ $y^0 \leftarrow y^n + \lambda^k d^k$


- ❻ $k \leftarrow k + 1$

- ❸ retornar y^0

$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de Hooke y Jeeves



$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de Hooke y Jeeves



Incluir una nueva direccion no coordenada, destraba el proceso.

$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Método de descenso coordinado

- No es necesario el cálculo del gradiente (ni que exista).
- Convergencia aceptable si las variables están poco acopladas.

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Dirección de descenso

Dado $x \in \mathbb{R}^n$, $d \in \mathbb{R}^n$ es **dirección de descenso** en x si $f(x + \alpha d) < f(x)$ para α positivo suficientemente chico.


$f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^2$: Dirección de descenso

Dado $x \in \mathbb{R}^n$, $d \in \mathbb{R}^n$ es **dirección de descenso** en x si $f(x + \alpha d) < f(x)$ para α positivo suficientemente chico.

Dado $x \in \mathbb{R}^n$ y $d \in \mathbb{R}^n$. Si

$$\nabla f(x)^t d < 0$$

entonces d es dirección de descenso en x .



Demostración:

- Definimos $\phi(\alpha) = f(x + \alpha d)$
- $\phi'(\alpha) = \nabla^T f(x + \alpha d)d$
- $\phi(0) = f(x)$ y $\phi'(0) = \nabla^T f(x)d$
- Como

$$\phi'(0) = \lim_{\alpha \rightarrow 0} \frac{\phi(\alpha) - \phi(0)}{\alpha}$$

existe $\bar{\epsilon} > 0$ tal que $\forall t \in (0, \bar{\epsilon})$, los signos de $\phi'(0)$ y $\phi(\alpha) - \phi(0)$ son iguales.

- Como $\nabla^T f(x)d < 0$, entonces $\phi(\alpha) - \phi(0) < 0 \forall \alpha \in (0, \bar{\alpha})$.
- Esto implica que $f(x + \alpha d) < f(x) \forall \alpha \in (0, \bar{\alpha})$.

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Métodos de descenso

Esquema básico

- ❶ Inicializar $x^0 \in \mathbb{R}^n$, $k \leftarrow 0$
- ❷ Mientras no se cumpla el **criterio de parada**:
 - ❶ Si $\nabla f(x_k) < \epsilon$, PARAR.
 - ❷ Seleccionar d_k dirección de descenso: $\nabla f(x_k)^T d_k < 0$
 - ❸ Resolver el problema univariable: Elegir paso α_k tal que $f(x_k + \alpha_k d_k) < f(x_k)$
 - ❹ $x_{k+1} \leftarrow x_k + \alpha_k d_k$
 - ❺ $k \leftarrow k + 1$

Tenemos que definir:

- cómo calcular la dirección d_k
- cómo calcular la longitud del paso α_k (búsqueda unidireccional o lineal)

Búsqueda unidireccional

- Trade-off entre calidad y tiempo.
- Reducción sustancial de f .
- No insumir mucho tiempo en su cálculo.
- Elección ideal:

$$\alpha_k = \min_{\alpha \in \mathbb{R}_{\geq 0}} \phi(\alpha) = \min_{\alpha \in \mathbb{R}} f(x_k + \alpha d_k)$$

- En general es muy caro identificar este valor.
- El cálculo de un mínimo local ya es caro.
- Puede requerir muchas evaluaciones de f y tal vez de ∇f .
- Puede no dar suficiente decrecimiento de f .
- Búsqueda lineal inexacta:
 - reducción adecuada de f ,
 - a mínimo costo.

Condición simple y obvia:

$$f(x_k + \alpha_k d_k) < f(x_k)$$

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Métodos de descenso

Condición simple y obvia:

$$f(x_k + \alpha_k d_k) < f(x_k)$$

- ❶ Inicializar $x^0 \in \mathbb{R}^n$, $k \leftarrow 0$
- ❷ Mientras no se cumpla el **criterio de parada**:
 - ❶ Si $\nabla f(x_k) < \epsilon$, PARAR.
 - ❷ Seleccionar d_k dirección de descenso: $\nabla f(x_k)^T d_k < 0$
 - ❸ $\alpha_k \leftarrow 1$
 - ❹ Mientras $f(x_k + \alpha_k d_k) \geq f(x_k)$: $\alpha_k \leftarrow \alpha_k/2$
 - ❺ $x_{k+1} \leftarrow x_k + \alpha_k d_k$
 - ❻ $k \leftarrow k + 1$

$f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^2$: Métodos de descenso

- Si el algoritmo anterior para por $\nabla f(x_k) < \epsilon$, x_k será un candidato a minimizador.
- Si esta condición no se cumple, ¿siempre existe $\lim_{k \rightarrow \infty} x_k$?
- Si $\lim_{k \rightarrow \infty} x_k = x^*$, ¿ $\nabla f(x^*) = 0$?

- $f(x) = x^2$
- $\nabla f(x) = 2x$
- Ejecutar el algoritmo con:
 - $x_0 = 2$
 - $d_k = -\frac{1}{(k+1)(k+2)}$
- $x_k = 1 + \frac{1}{k+1}$
- $x_k \rightarrow 1$ cuando $k \rightarrow \infty$
- $f'(1) = 2$, 1 no es punto estacionario.

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Métodos de descenso


- $f(x) = x^2$
 - $\nabla f(x) = 2x$
 - Ejecutar el algoritmo con:
 - $x_0 = 2$
 - $d_k = -\frac{1}{(k+1)(k+2)}$
 - $x_k = 1 + \frac{1}{k+1}$
 - $x_k \rightarrow 1$ cuando $k \rightarrow \infty$
 - $f'(1) = 2$, 1 no es punto estacionario.
-
- Lo que sucede es que la distancia entre x_k y x_{k+1} se aproxima a 0 muy rápido comparado al decrecimiento de la función.
 - También puede pasar que aunque x_k y x_{k+1} estén a distancia, el decrecimiento de la función sea arbitrariamente chico.

- $f(x) = x^2$
- $\nabla f(x) = 2x$
- Ejecutar el algoritmo con:
 - $x_0 = 1$
 - $d_k = -\frac{1}{(k+1)(k+2)}$
- $x_k = \frac{1}{k+1}$
- $x_k \rightarrow 0$ cuando $k \rightarrow \infty$
- $f'(0) = 0$, 0 es punto estacionario.

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Métodos de descenso

¿Que ocurre con el paso α_k ?

Hay que evitar pasos **muy largos** y pasos **muy cortos**




Paso largo

$$x_0 = 2$$

$$p_k = (-1)^{k+1}$$

$$\alpha_k = \frac{3}{2^{k+1}}$$

$$x_{k+1} = x_k - (-1)^{k+1} \frac{3}{2^{k+1}}$$



Paso corto

$$x_0 = 2$$

$$p_k = -1$$

$$\alpha_k = \frac{1}{2^{k+1}}$$

$$x_{k+1} = x_k - \frac{1}{2^{k+1}}$$

Condición

$$\|d_k\| \geq \sigma \|\nabla f(x_k)^T\| \quad \forall k$$

con $\sigma > 0$.

Condición

$$\|d_k\| \geq \sigma \|\nabla f(x_k)^T\| \quad \forall k$$

con $\sigma > 0$.

- Impide que los pasos se aproximen muy rápido a 0.
- Si $\|d_k\| \rightarrow 0$, entonces $\|\nabla f(x_k)^T\| \rightarrow 0$.

Condición del ángulo


$$\nabla f^T(x_k)d_k \leq -\theta \|\nabla f^T(x_k)\| \|d_k\|$$

con $\theta \in (0, 1]$.

Condición del ángulo

$$\nabla f^T(x_k)d_k \leq -\theta \|\nabla f^T(x_k)\| \|d_k\|$$

con $\theta \in (0, 1]$.



- Se busca que la dirección sea de descenso, forme un ángulo *no cercano* a $\pi/2$ con $-\nabla f^T(x_k)$.
- Si $\nabla f^T(x_k)d_k \approx 0$ se darán pasos muy cortos.
- Si $\theta = 1$, $d_k = -\nabla f^T(x_k)$.

Criterio de Armijo

Decrecimiento suficiente si:

$$\phi(\alpha_k) = f(x_k + \alpha_k d_k) < f(x_k) + c_1 \alpha_k \nabla f^T(x_k) d_k$$

con $c_1 \in (0, 1)$.

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Búsqueda lineal

Criterio de Armijo

Decrecimiento suficiente si:

$$\phi(\alpha_k) = f(x_k + \alpha_k d_k) < f(x_k) + c_1 \alpha_k \nabla f^T(x_k) d_k$$


con $c_1 \in (0, 1)$.

- Asegurar que cada paso proporcione una reducción suficiente en la función objetivo.
- Obliga a que el decrecimiento sea proporcional al tamaño del paso.
- Evita pasos grandes con poco decrecimiento de f .



$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Criterio de Armijo

$$l(\alpha) = f(x_k) + c_1 \alpha \nabla f^T(x_k) d_k$$

- Pendiente de $l(\alpha) = c_1 \nabla f^T(x_k) d_k$ negativa.



$f : \mathbb{R}^n \rightarrow \mathbb{R}$: Criterio de Armijo



Algoritmo básico

- ➊ Inicializar $x^0 \in \mathbb{R}^n$, $k \leftarrow 0$, $\sigma > 0$, $\theta \in (0, 1]$, $c_1 \in (0, 1)$
- ➋ Mientras no se cumpla el **criterio de parada**:
 - ➊ Si $\|\nabla f(x_k)\| < \epsilon$, PARAR.
 - ➋ Seleccionar d_k dirección de descenso, tal que:
 - $\|d_k\| \geq \sigma \|\nabla f^T(x_k)\|$
 - $\nabla f^T(x_k) d_k \leq -\theta \|\nabla f^T(x_k)\| \|d_k\|$
 - ➌ $\alpha_k \leftarrow 1$
 - ➍ Mientras $f(x_k + \alpha_k d_k) \geq f(x_k) + c_1 \alpha_k \nabla f^T(x_k) d_k$:
 - seleccionar $\alpha_k \in (0.1\alpha_k, 0.9\alpha_k)$
 - ➎ $x_{k+1} \leftarrow x_k + \alpha_k d_k$
 - ➏ $k \leftarrow k + 1$

El algoritmo básico:

- Termina por $\nabla f(x_k) < \epsilon$,
- o genera una secuencia infinita x_k tal que si x^* es punto de acumulación de la secuencia, entonces $\nabla f(x^*) = 0$.

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Métodos de descenso

El algoritmo básico:

- Termina por $\nabla f(x_k) < \epsilon$,
- o genera una secuencia infinita x_k tal que si x^* es punto de acumulación de la secuencia, entonces $\nabla f(x^*) = 0$.

Mejora de criterios para el paso

- Criterio de Wolfe (condición de curvatura).
- Criterio de Goldstein.

$f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^2$: Búsqueda lineal

Criterio de Wolfe

$$\nabla f(x_k + \alpha_k d_k)^T d_k \geq c_2 \nabla f(x_k)^T d_k$$


para $c_2 \in (c_1, 1)$.

- Es decir,

$$\phi'(\alpha_k) \geq c_2 \phi'(0).$$

- Si la pendiente de $\phi(\alpha_k)$ es muy negativa, aumentando el valor de α se obtendrían reducciones significativas de f .
- En cambio, si la pendiente de $\phi(\alpha_k)$ es poco negativa o positiva, no es esperable obtener reducciones significativas de f en esa dirección.
- Evita pasos excesivamente pequeños.

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Condiciones de Wolfe




Criterio de Goldstein

$$f(x_k) + (1 - c)\alpha_k \nabla f^T(x_k) d_k < \phi(\alpha_k) < f(x_k) + c\alpha_k \nabla f^T(x_k) d_k$$

con $c \in (0, 1/2)$.

- Evita pasos excesivamente pequeños.
- Puede excluir minimizadores de ϕ .
- Buenos resultados en métodos tipo Newton.

$f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^2$: Condiciones de Goldstein



$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Direcciones de descenso

- Método del gradiente (mayor descenso)
- Método de direcciones conjugadas
- Método de Newton
- Método Quasi Newton

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Método del gradiente

Se elige $d_k = -\nabla f(x_k)$

Algoritmo del gradiente

- ❶ Inicializar $x^0 \in \mathbb{R}^n$, $k \leftarrow 0$, $c_1 \in (0, 1)$
- ❷ Mientras no se cumpla el **criterio de parada**:
 - ❶ Si $\|\nabla f(x_k)\| < \epsilon$, PARAR.
 - ❷ $\alpha_k \leftarrow 1$
 - ❸ Mientras $f(x_k - \alpha_k \nabla f(x_k)) \geq f(x_k) - c_1 \alpha_k \nabla^T f(x_k) \nabla f(x_k)$:
 - seleccionar $\alpha_k \in (0.1\alpha_k, 0.9\alpha_k)$
 - ❹ $x_{k+1} \leftarrow x_k - \alpha_k \nabla f(x_k)$
 - ❺ $k \leftarrow k + 1$

$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Método del gradiente

Caso cuadrático

- $f(x) = \frac{1}{2}x^T Gx + b^T x$, con G definida positiva
- $\nabla f(x) = Gx + b$
- $\phi(\alpha) = f(x_k) - \alpha \|\nabla f(x_k)\|^2 + \alpha^2 \nabla f(x_k)^T G \nabla f(x_k)$
- $\phi'(\alpha) = -\|\nabla f(x_k)\|^2 + \alpha \nabla f^T(x_k) G \nabla f(x_k)$
- Haciendo $\phi'(\alpha) = 0$ se obtiene el mínimo global de $\phi(\alpha)$
- $\arg \min_{\alpha \in \mathbb{R}} \phi(\alpha) = \frac{\|\nabla f(x_k)\|^2}{\nabla^T f(x_k) G \nabla f(x_k)}$

$f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^2$: Método del gradiente

Caso cuadrático

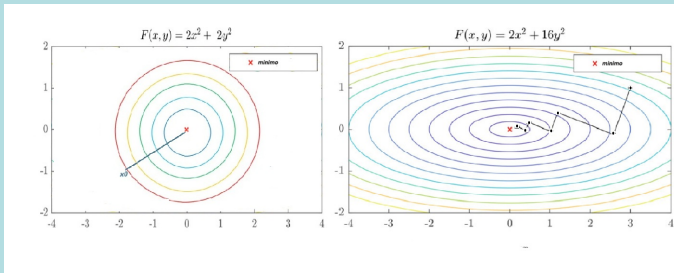
- $f(x) = \frac{1}{2}x^T Gx + b^T x$, con G definida positiva
- $\nabla f(x) = Gx + b$
- $\phi(\alpha) = f(x_k) - \alpha \|\nabla f(x_k)\|^2 + \alpha^2 \nabla f(x_k)^T G \nabla f(x_k)$
- $\phi'(\alpha) = -\|\nabla f(x_k)\|^2 + \alpha \nabla f^T(x_k) G \nabla f(x_k)$
- Haciendo $\phi'(\alpha) = 0$ se obtiene el mínimo global de $\phi(\alpha)$
- $\arg \min_{\alpha \in \mathbb{R}} \phi(\alpha) = \frac{\|\nabla f(x_k)\|^2}{\nabla^T f(x_k) G \nabla f(x_k)}$

Algoritmo caso cuadrático

- 1 Inicializar $x^0 \in \mathbb{R}^n$, $k \leftarrow 0$
- 2 Mientras no se cumpla el **criterio de parada**:
 - 1 Si $\nabla f(x_k) < \epsilon$, PARAR.
 - 2 $x_{k+1} \leftarrow x_k + \frac{\|\nabla f(x_k)\|^2}{\nabla^T f(x_k) G \nabla f(x_k)} (Gx_k + b)$
 - 3 $k \leftarrow k + 1$

Caso cuadrático Método del gradiente

Algoritmo caso cuadrático



Caso cuadrático

Se puede establecer una cota del descenso entre iteraciones.

$$f(x_{k+1}) - f(x^*) \leq \left(\frac{\lambda_{\max} - \lambda_{\min}}{\lambda_{\max} + \lambda_{\min}} \right)^2 (f(x_k) - f(x^*))$$

donde λ_{\max} y λ_{\min} son los autovalores máximo y mínimo de G

Caso cuadrático

- Si G es diagonal, las curvas de nivel son elipses *alineadas* con los ejes cartesianos. Tomar como direcciones a los ejes coordenados, lleva al óptimo en un número finito de pasos.
- Si G no es diagonal, no hay una alineación con los ejes y la convergencia puede resultar muy lenta si nos movemos por ellos.

$f : \mathbb{R}^n \rightarrow \mathbb{R}$, $f \in C^2$: Método de direcciones

Caso cuadrático

- Sean p_0, p_1, \dots, p_{n-1} tales que $p_i G p_j = 0$.
- Se puede demostrar que estos vectores son l.i.
- Definimos S una matriz de $n \times n$ tal que $S = [p_0 p_1 \dots p_{n-1}]$.
- Sea $x = S \bar{x}$
- Realizando un cambio de variable,
$$\frac{1}{2} x^T G x + b^T x = \frac{1}{2} \bar{x}^T S^T G S \bar{x} + S^T b^T \bar{x}$$
- Como $p_i G p_j = 0$ resulta que $S^T G S = D$, matriz diagonal y por lo tanto servirán los ejes coordenados como direcciones.
- Viéndolo en las variables originales, corresponde a tomar como direcciones a los p_i .

¿Cómo encontramos p_0, p_1, \dots, p_{n-1} ?

Caso cuadrático

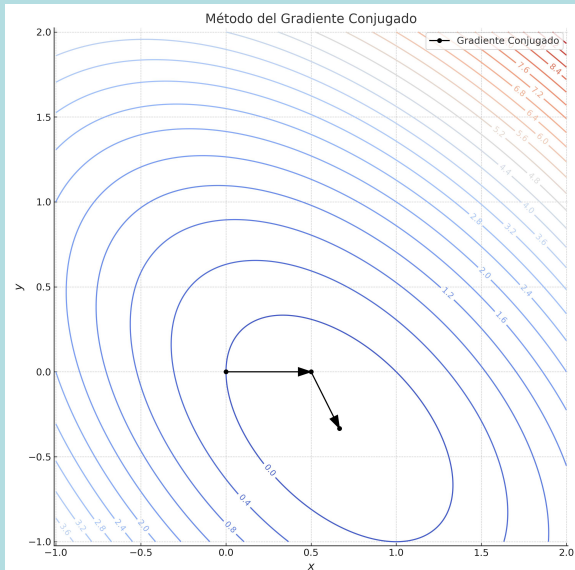
- Por descomposición SVD, $A = UDU^T$ donde D tiene en la diagonal los autovalores de A y las columnas de U son una base ortonormal de autovectores de A^2 .
- Método de gradiente conjugado: generarlos a demanda y la dirección es una combinación lineal del gradiente actual y la dirección anterior:

$$d_{k+1} = -\nabla f(x_{k+1}) + \beta d_k, \text{ con } \beta = \frac{\nabla^T f(x_{k+1}) G d_k}{d_k^T G d_k}$$

y $d_0 = -\nabla f(x_0)$

Gradiente conjugado

Caso cuadrático



$f : \mathbb{R}^n \rightarrow \mathbb{R}, f \in C^2$: Método de Newton

Primera interpretación

- Se considera una *aproximación cuadrática* basada en la expresión de Taylor:

$$f(x_k + p) = f(x_k) + \nabla f(x_k)p + \frac{1}{2}p^T H(x_k)p$$

Donde $H(x_k)$ es la matriz hessiana de f en x_k . Asumimos $H(x_k)$ simétrica y definida positiva.

- Se busca el mínimo de esta función. Se alcanza en p_k con $H(x_k)p_k = -\nabla f(x_k)$
- Podemos considerar entonces a p_k como una dirección de descenso y definir

$$x_{k+1} = x_k - p_k = x_k - H(x_k)^{-1}\nabla f(x_k)$$

Segunda interpretación

- Se aproxima en orden 1 a la función gradiente

$$\nabla f(x) = H(x_k)(x - x_k) + \nabla f(x_k)$$

- Se busca x donde se anula

$$x_{k+1} = x_k - H(x_k)^{-1} \nabla f(x_k)$$

Teorema

Si x_0 esta suficientemente cerca de x^ , f es C^2 , la matriz hessiana es definida positiva y satisface condición de Lipschitz en una vecindad de x^* entonces la sucesión converge a x^* y el orden es cuadrático.*

Modificaciones:

- Realizar una búsqueda en la dirección p_k , resulta entonces
$$x_{k+1} = x_k - \alpha_k p_k$$
- Si la matriz hessiana no es definida positiva, remplazarla por $H(x_k) + \mu I$

- Utilizan modelos cuadráticos

$M_k(p) = f(x_k) + \nabla f(x_k)p + \frac{1}{2}p^T B_k p$ con B_k definida positiva y se define

$$x_{k+1} = x_k + \alpha_k p_k \text{ con } p_k = -B_k^{-1} \nabla f(x_k)$$

- Se busca que el gradiente de $M_{k+1}(x)$ evaluado en x_{k+1} y x_k coincida con el valor del gradiente de f en esos puntos.
- De la condición anterior, surge que

$$B_{k+1}(x_{k+1} - x_k) = \nabla f(x_{k+1}) - \nabla f(x_k)$$

ECUACIÓN SECANTE

- No está unívocamente determinada. ¿Cómo hacerlo?

$$\min_{B \in \mathbb{R}^{n \times n}} ||B - B_k||$$

sujeto a B simétrica def positiva y satisface ecuación secante.

- Diferentes normas matriciales dieron origen a diferentes métodos.
- Los más conocidos son el método BFGS (Broyden-Fletcher-Goldfarb-Shanno) y el DFP (Davidon-Fletcher-Powell) con reglas de actualización de una iteración a otra.
- Se pierde la convergencia con orden cuadrático.